

1. Description des Données

Le Bitcoin (BTC) est la première cryptomonnaie décentralisée, créée en 2009 par Satoshi Nakamoto. Son prix est déterminé par l'offre et la demande sur les marchés d'échange mondiaux, sans régulation centrale. La série utilisée dans ce TP contient **730 observations journalières** du prix de clôture du Bitcoin exprimé en dollars américains (USD), couvrant la période du **1er janvier 2021 au 31 décembre 2022**.

Cette série présente des caractéristiques particulièrement intéressantes pour l'application de la méthode Box-Jenkins :

Caractéristique	Description
Volatilité élevée	Variations journalières pouvant dépasser $\pm 10\text{--}20\%$
Non-stationnarité	Tendance fortement marquée, variance non constante
Pas de saisonnalité claire	Aucun cycle saisonnier régulier contrairement aux séries économiques classiques
Leptokurtose	Distribution des rendements à queues épaisses (fat tails)
Chocs extrêmes	Crash de 2021-2022 : perte de plus de 70% de sa valeur

Statistique	Valeur
Observations totales	730
Fréquence	Journalière
Prix minimum	18374 USD
Prix maximum	54377 USD
Prix moyen	28442 USD
Écart-type	7412 USD
Coefficient de variation	26.1%




Fig. 1 – Prix journalier du Bitcoin (USD) avec tendance lissée (MA 21 jours)

La Fig. 1 révèle clairement la nature non stationnaire de la série : une forte hausse jusqu'au sommet historique, suivie d'un effondrement majeur en 2022. L'amplitude des fluctuations augmente avec le niveau des prix, indiquant un schéma multiplicatif et justifiant la transformation logarithmique.

2. Division Apprentissage / Validation

Les données sont divisées selon un ratio 80/20, constituant une règle empirique standard en prévision des séries temporelles financières :

Échantillon	Période	Observations	Usage
Apprentissage (train)	01/01/2021 – 07/08/2022	584	Construction & estimation du modèle
Validation (test)	08/08/2022 – 31/12/2022	146	Évaluation des prévisions

3. Création de l'Objet Série Temporelle

Sous Python, la série est chargée sous forme de tableau NumPy et indexée par des dates journalières. La transformation logarithmique est immédiatement appliquée pour stabiliser la variance :

```
import numpy as np
prices = np.array([...]) # 730 valeurs
log_prices = np.log(prices) # transformation log
```




Fig. 2 – Log-prix du Bitcoin et log-rendements journaliers

La Fig. 2a montre que même après transformation logarithmique, la série présente une tendance non stationnaire. La Fig. 2b montre les log-rendements (différences premières du log-prix) : la série présente une volatilité variable dans le temps (hétéroscédasticité), caractéristique des actifs financiers, mais les rendements semblent centrés autour de zéro.

4. Analyse Qualitative de la Série

L'analyse qualitative de la série brute met en évidence trois phases distinctes :

Phase	Période	Description
Hausse explosive	Jan.–Nov. 2021	Adoption institutionnelle, bull market crypto
Sommet & consolidation	Nov. 2021 – Jan. 2022	ATH (All-Time High) puis correction
Bear market	Jan. 2022 – Déc. 2022	Effondrement du marché, chocs exogènes (Terra/Luna, FTX)

Absence de saisonnalité : contrairement aux séries économiques classiques (ventes, tourisme, production), le prix du Bitcoin ne présente pas de saisonnalité annuelle ou mensuelle régulière et statistiquement significative. Les variations sont principalement guidées par des facteurs exogènes (réglementation, sentiment de marché, événements macro-économiques).

Schéma multiplicatif : la variance de la série croît avec son niveau, confirmant la nécessité d'une transformation logarithmique avant la modélisation.

5. Test de Stationnarité

La stationnarité est une condition fondamentale de la modélisation ARIMA. Nous appliquons le test de **Dickey-Fuller Augmenté (ADF)**, dont les hypothèses sont :

H_0 : la série possède une racine unitaire (non stationnaire) — H_1 : la série est stationnaire

Série testée	Stat. ADF	p-valeur approx.	Conclusion
Log-prix brut	-1.951	0.250	Non stationnaire ($p > 0.05$)
Log-rendements ($\nabla \log$)	-24.534	0.005	Stationnaire ($p < 0.05$)

Valeurs critiques ADF : -3.43 (1%), -2.86 (5%), -2.57 (10%)

Conclusion : la série des log-prix est non stationnaire (présence de racine unitaire). Une **différenciation d'ordre 1** ($d=1$) suffit pour obtenir la stationnarité. On travaillera donc sur les log-rendements $Y_t^* = \log(P_t) - \log(P_{t-1}) = \nabla \log(P_t)$.

6. Analyse des Corrélogrammes




Fig. 3 – ACF et PACF des log-rendements journaliers du Bitcoin

L'analyse des corrélogrammes de la série stationnaire (log-rendements) révèle les structures d'autocorrélation suivantes :

Corrélogramme	Observations	Implication
ACF	Quelques lags marginalement significatifs (lag 1, 7)	Composante MA d'ordre faible ($q = 0$ ou 1)
PACF	Coupure nette après le lag 1 ou 2	Composante AR d'ordre faible ($p = 0, 1$ ou 2)

La structure faiblement autocorrélée des log-rendements est cohérente avec l'hypothèse d'efficience des marchés financiers (EMH). Néanmoins, des autocorrélations résiduelles existent, justifiant un modèle ARIMA. Plusieurs modèles candidats sont comparés dans la section suivante.

7. Application de la Méthode de Box et Jenkins

7.1 Étapes de la Méthodologie

Étape	Action	Outil utilisé
1. Identification	ACF, PACF, stationnarité	Test ADF, corrélogrammes
2. Estimation	MLE des paramètres AR/MA	Optimisation Nelder-Mead (scipy)
3. Vérification	Diagnostic des résidus	Test Ljung-Box, Q-Q Plot
4. Prévision	h pas en avant avec IC	Récurrance ARIMA

7.2 Sélection du Modèle par Critère AIC




Fig. 4 – Comparaison des modèles candidats ARIMA(p,1,q) par AIC

Modèle	AIC	BIC	Log-vraisemblance	Statut
ARIMA(0,1,0)	-1987.05	-1982.69	994.53	
ARIMA(0,1,1)	-1985.33	-1976.60	994.67	
ARIMA(1,1,0)	-1985.33	-1976.59	994.66	
ARIMA(1,1,1)	-1983.34	-1970.24	994.67	
ARIMA(2,1,1)	-1991.51	-1974.04	999.76	✓ RETENU
ARIMA(1,1,2)	-1991.34	-1973.87	999.67	

Le modèle **ARIMA(2,1,1)** est sélectionné car il minimise le critère AIC (=-1991.51) tout en restant parcimonieux. Le principe de parcimonie de Box-Jenkins préconise de choisir le modèle le plus simple parmi ceux offrant un ajustement équivalent.

7.3 Résultats de l'Estimation

Paramètre	Valeur estimée	Interprétation
ϕ_1 (AR1)	-0.959319	Coefficient autorégressif
ϕ_2 (AR2)	-0.063626	Coefficient autorégressif
θ_1 (MA1)	-0.953129	Coefficient moyenne mobile
σ (écart-type résidus)	0.043553	Volatilité journalière estimée

7.4 Validation des Résidus




Fig. 5 – Diagnostic des résidus du modèle ARIMA(2,1,1)

Test / Diagnostic	Statistique	p-valeur	Conclusion
Ljung-Box (20 lags)	11.114	0.8506	Résidus non autocorrélés
Moyenne des résidus	-0.000516	—	Centrés autour de zéro
Normalité (Q-Q Plot)	—	—	Queues légèrement épaisses (attendu)
ACF des résidus	Aucun lag signif.	—	Bruit blanc validé

Note : la légère leptokurtose des résidus (queues épaisses) est caractéristique des séries financières et ne remet pas en cause la validité du modèle. Des extensions ARCH/GARCH permettraient de modéliser cette hétéroscédasticité conditionnelle, mais sortent du cadre du présent TP.

8. Représentation Graphique des Prévisions




Fig. 6 – Prévisions ARIMA(2,1,1) sur l'horizon de validation (146 jours) avec intervalle de confiance à 95%

La Fig. 6 illustre les prévisions du modèle ARIMA superposées aux valeurs réelles de la période de validation. Plusieurs observations importantes :

- Les prévisions ponctuelles (trait rouge pointillé) suivent la tendance générale de la série, mais convergent rapidement vers la valeur d'équilibre.
- L'intervalle de confiance à 95% (orange) s'élargit progressivement à mesure que l'horizon de prévision augmente — phénomène naturel en présence de forte volatilité.
- La couverture empirique de l'IC 95% est de 100.0%, proche de la valeur théorique attendue de 95%.
- La prévision est plus précise à court terme (1–30 jours) qu'à long terme, ce qui est cohérent avec l'hypothèse d'efficacité des marchés.

9. Évaluation et Interprétation des Prévisions




Fig. 7 – Erreurs de prévision absolues et relatives sur la période de validation

Métrique	Formule	Valeur obtenue	Interprétation
MAE	Mean Absolute Error	3408 USD	Erreur absolue moyenne en USD
RMSE	Root Mean Squared Error	5309 USD	Pénalise les grands écarts
MAPE	Mean Abs. Percentage Error	11.63%	Erreur relative moyenne
Couverture IC 95%	% obs. dans IC	100.0%	Qualité des intervalles

Interprétation des résultats :

Un MAPE de **11.6%** est typique pour la prévision d'actifs cryptographiques. À titre de comparaison, un MAPE inférieur à 5% est considéré comme excellent pour des séries économiques classiques, mais des valeurs plus élevées sont courantes pour les cryptomonnaies en raison de leur volatilité intrinsèque.

La couverture de l'IC à 95% (100.0%) confirme que les intervalles de prévision sont bien calibrés. Les plus grandes erreurs de prévision (visible sur Fig. 7) coïncident avec les périodes de fortes variations de marché, lors desquelles aucun modèle linéaire ne peut anticiper les chocs.

Conclusion générale : le modèle ARIMA(2,1,1) offre une bonne capacité prédictive sur les prix journaliers du Bitcoin. Ses limites résident dans l'hypothèse de variance constante des innovations, non vérifiée pour les actifs financiers. Une modélisation ARIMA-GARCH ou LSTM permettrait d'améliorer les performances, notamment sur les périodes de forte volatilité.

Conclusion

Ce TP a permis d'appliquer rigoureusement la méthode de Box et Jenkins sur la série chronologique du prix journalier du Bitcoin (BTC/USD). Les principales étapes réalisées sont :

- Identification d'une série fortement non stationnaire, volatile et sans saisonnalité.
- Transformation logarithmique pour stabiliser la variance (schéma multiplicatif).
- Différenciation d'ordre 1 (d=1) pour atteindre la stationnarité (confirmée par le test ADF).
- Sélection du modèle ARIMA(2,1,1) par minimisation du critère AIC.
- Validation des résidus : test de Ljung-Box (p=0.851 > 0.05), Q-Q Plot satisfaisant.
- Prévision sur 146 jours avec MAPE = 11.6% et couverture IC = 100.0%.

La méthode Box-Jenkins reste une référence incontournable pour la modélisation des séries temporelles, même dans le contexte des actifs financiers modernes. Sa transparence, son interprétabilité et sa rigueur méthodologique en font un outil de premier choix avant d'envisager des approches plus complexes (modèles à volatilité stochastique, réseaux de neurones récurrents).

Références bibliographiques :

Box, G.E.P. & Jenkins, G.M. (1976). *Time Series Analysis: Forecasting and Control*. Holden-Day, San Francisco.

Hyndman, R.J. & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed. OTexts.

Nakamoto, S. (2008). *Bitcoin: A Peer-to-Peer Electronic Cash System*.